

RECONNAISSANCE DE LANGUE DES SIGNES CLASSIFICATION D'ACTIONS



Presented by:

BENELMAHI Hicham
Ferrah Othmane
EL KARCHAL Soufiane

Supervised by:

Pr. BEKRI Moulay Ali

TABLE DES MATIÈRES

Introduction

Contexte

Problématique

Objectifs

Architecture du pipeline

Méthodologie

Dataset

Obtention du Modèle

Résultats

Démonstration

Conclusion



INTRODUCTION

La langue des signes est un langage visuel très riche et structuré, qui permet à des millions de personnes sourdes et malentendantes de communiquer au quotidien.

Cependant, il existe encore une barrière importante entre les utilisateurs de la langue des signes et ceux qui ne la maîtrisent pas, ce qui rend la communication et l'inclusion sociale difficiles.

L'objectif de notre projet est donc de réduire cette barrière, en développant un système intelligent capable de reconnaître automatiquement les gestes de la langue des signes à partir de vidéos. Pour cela, nous combinons des techniques avancées de vision par ordinateur (comme **YOLOv8** et **MediaPipe**) avec des modèles d'apprentissage profond (notamment un **LSTM**).



CONTEXTE

La langue des signes est un système linguistique complet utilisant :

- Les gestes des mains
- Les expressions faciales
- La posture du corps pour transmettre du sens.

Elle représente le principal moyen de communication pour les personnes sourdes et malentendantes.

Aujourd'hui, l'intégration des technologies de **vision par ordinateur** et **d'intelligence artificielle** ouvre des perspectives prometteuses pour :

- La traduction automatique
- L'accessibilité numérique
- L'inclusion sociale

OBJECTIFS

OBJECTIF PRINCIPAL

Développer un système capable de reconnaître des gestes de langue des signes à partir de vidéos (sign language recognition).

OBJECTIFS SPÉCIFIQUES

- Utiliser **YOLOv8** pour la hand detection
- Utiliser **MediaPipe Hands** pour l'extraction des
- Concevoir un modèle **LSTM (Long Short-Term Memory)** pour la gesture classification
- Déployer une **web application** intuitive et fonctionnelle


PROBLÉMATIQUE

Bien que la langue des signes soit essentielle à la communication des personnes sourdes et malentendantes, il existe encore peu de systèmes capables de la reconnaître automatiquement de manière précise et en temps réel.

Les principaux défis sont :

- **Variations des gestes (vitesse, style)**
- **Différences de position et d'éclairage**
- **Manque de grands datasets**
- **Besoin d'un système rapide et précis**

ARCHITECTURE DU PIPELINE



L'utilisateur upload une vidéo du signe à reconnaître.

Détection des personnes sur chaque frame grâce à YOLOv8, un modèle d'object detection rapide et précis.


Extraction des 21 keypoints par main (coordonnées x,y normalisées) à l'aide de MediaPipe Hands

Séquençage des keypoints sur 30 frames pour former un vecteur temporel complet.

Passage de la séquence dans un modèle LSTM (Long Short-Term Memory) qui prédit la classe du geste réalisé

Affichage du résultat avec la classe prédite et les scores de confiance dans l'application web.

GÉNÉRATION DE VIDÉOS FACTICES



EXEMPLE DE VIDÉOS GÉNÉRÉES



sign_A F42



sign_A F62

MÉTHODOLOGIE

PERSON DETECTION – YOLOV8



YOLOv8 (You Only Look Once version 8) est un modèle d'object detection basé sur des réseaux de neurones , permettant de détecter en temps réel des objets dans une image ou une vidéo.

- Utilisation de YOLOv8n (nano), version légère et rapide.
- Application sur chaque frame vidéo pour détecter les personnes.
- Seuil de confiance : 0.4
- Génération de bounding boxes autour des personnes détectées pour isoler les régions d'intérêt (ROI).

MÉTHODOLOGIE



KEYPOINTS EXTRACTION (MEDIAPIPE HANDS)

MediaPipe Hands est une solution de Google basée sur l'IA pour la détection et le tracking en temps réel des mains, capable d'extraire les points clés (keypoints) décrivant la structure de la main.

- Extraction de **21 keypoints par main** (coordonnées x, y normalisées).
- Support de 2 mains simultanément.
- Chaque frame produit un vecteur de **84 features** : 2 mains × 21 points × 2 coordonnées).

MÉTHODOLOGIE

GESTURE CLASSIFICATION – LSTM

LSTM (Long Short-Term Memory) est un type de réseau neuronal récurrent capable d'apprendre des dépendances temporelles longues, souvent utilisé pour la modélisation de séquences.

- Développement d'un modèle LSTM bidirectionnel.
- Architecture :
 - 2 couches LSTM
 - 256 hidden units
 - Dropout 0.3
- Input : séquence de 70 frames × 84 features
- Output : prédiction de la classe du geste parmi 4 classes : clavier, disque dur, ordinateur, souris

DATASET

COMPOSITION DU DATASET

- 199 vidéos au total
- 4 classes : **clavier, disque dur, ordinateur, souris**

```
✓ SignLanguageDataset
  > clavier
  > disque_dur
  > ordinateur
  > souris
```

RÉPARTITION DES DONNÉES (DATA SPLIT)

Pourquoi ?

Pour évaluer la performance du modèle de façon objective et éviter l'overfitting.

- **Training set** : utilisé pour entraîner le modèle (80%)
- **Validation set** : utilisé pour ajuster les hyperparamètres et monitorer la performance pendant l'entraînement
- **Test set** : utilisé uniquement pour évaluer la performance finale du modèle sur des données jamais vues

DATASET

RÉPARTITION DES DONNÉES (DATA SPLIT)


Comment ?

- **Train** : 139 vidéos (80%)
- **Validation** : 40 vidéos (10%)
- **Test** : 20 vidéos (10%)

PRÉTRAITEMENT


- Extraction des frames vidéo
- person detection (YOLOv8)
- Keypoints extraction (MediaPipe Hands)
- Séquençage à 70 frames par vidéo (padding ou truncation)
- Stockage optimisé au format HDF5 + JSON (label map)

COMMENT ÇA PASSE ?



VIDÉO


COMPOSÉ DE PLUSIEURS FRAMES



C'EST QUOI UN FRAME




DÉTECTION DES PERSONNES PAR YOLO





DÉTECTION DES PERSONNES PAR YOLO

Frame 35 - Keypoints shape: (84,)



DÉTECTION DES MAINS ET EXTRACTION DES KEYPOINTS



- Main gauche : 21 points (x, y) $\rightarrow$ 42 valeurs
- Main droite : 21 points (x, y) $\rightarrow$ 42 valeurs
- Total par image = 84 valeurs

APRÈS L'EXTRACTION DES VALEURS

Point	Main	x	y
0	Gauche	0.321	0.453
1	Gauche	0.344	0.467
...	...	...	...
20	Gauche	0.512	0.621
0	Droite	0.654	0.43
...	...	...	...
20	Droite	0.703	0.585

COMMENT S'ENREGISTRE DANS
HDF5



- Vidéo : sign_A_vid1.mp4
- Nombre de frames: 70
- → Séquence = tableau 70 × 84 (shape : (70, 84))

OBTENTION DU MODÈLE

PRÉPARATION DES DONNÉES

- Extraction des keypoints (MediaPipe) après détection des mains (YOLOv8).
- Création de séquences de 70 frames normalisées par vidéo.
- Stockage sous format HDF5 pour un accès rapide lors de l'entraînement.

CONCEPTION DU MODÈLE – LSTM

Fonction utilisée

```
class LSTMClassifier(L.LightningModule):  
    def __init__(self, input_size, hidden_size, num_layers, num_classes, dropout, learning_rate, weight_decay):
```

OBTENTION DU MODÈLE

CONCEPTION DU MODÈLE – LSTM

Fonction utilisée

```
class LSTMClassifier(L.LightningModule):  
    def __init__(self, input_size, hidden_size, num_layers, num_classes, dropout, learning_rate, weight_decay):
```

input_size = 84

(2 mains × 21 keypoints × 2 coordonnées)

hidden_size = 256

Taille des couches cachées LSTM, définit la capacité de mémorisation du modèle.

OBTENTION DU MODÈLE

CONCEPTION DU MODÈLE – LSTM

Fonction utilisée

```
class LSTMClassifier(L.LightningModule):  
    def __init__(self, input_size, hidden_size, num_layers, num_classes, dropout, learning_rate, weight_decay):
```

num_layers = 2

Nombre de couches empilées, améliore l'apprentissage de patterns complexes.

num_classes = 4


Nombre de classes de sortie : clavier, disque dur, ordinateur, souris.

OBTENTION DU MODÈLE

ENTRAÎNEMENT ET VALIDATION

Loss Curve

- **Définition** : courbe représentant l'évolution de la loss function (erreur de prédiction) sur le training set et le validation set au fil des epochs.
- **Interprétation** : une loss qui diminue indique que le modèle apprend à mieux prédire.




OBTENTION DU MODÈLE

ENTRAÎNEMENT ET VALIDATION

F1-Score Curve

- **Définition** : courbe montrant l'évolution du F1-score macro, qui combine précision et rappel pour mesurer la performance globale du modèle.
- **Interprétation** : une F1-score curve qui augmente indique une meilleure capacité de classification équilibrée entre classes.



OBTENTION DU MODÈLE

ENTRAÎNEMENT ET VALIDATION

Classification metrics

- **Définition** : Les classification metrics mesurent la performance du modèle sur le test set.
 - **Precision** : proportion de prédictions correctes parmi les prédictions positives.
 - **Recall** : proportion de prédictions correctes parmi les échantillons réels de la classe.
 - **F1-score** : moyenne harmonique de la precision et du recall, mesure équilibrée de performance

Classification Report (Test Set):				
	precision	recall	f1-score	support
clavier	1.00	1.00	1.00	5
disque_dur	0.57	0.80	0.67	5
ordinateur	0.83	1.00	0.91	5
souris	1.00	0.40	0.57	5
accuracy			0.80	20
macro avg	0.85	0.80	0.79	20
weighted avg	0.85	0.80	0.79	20

Macro F1-score : 79%


Accuracy : 80%

OBTENTION DU MODÈLE - RÉSULTATS

ENTRAÎNEMENT ET VALIDATION

Confusion matrix

- **Définition** : tableau comparant les classes réelles et prédites pour visualiser performances et erreurs.
- **Interprétation** : une diagonale forte = bonnes prédictions, hors diagonale = confusions entre classes.



APPLICATION WEB

Une application web (Flask web app) permettant aux utilisateurs d'interagir directement avec le modèle de reconnaissance de langue des signes via une interface intuitive.

↑ Télécharger une Vidéo



Déposez votre fichier vidéo ici
ou cliquez pour parcourir les fichiers


Supporte MP4, AVI, MOV (max 16MB)

Choisir un Fichier

📹 Enregistrer une Vidéo

📹 Commencer l'Enregistrement

Aperçu de la Vidéo



Vidéo traitée avec succès !



Reconnaissance Terminée

ordinateur

Confiance : 85.5%

clavier 14.4%

disque_dur 0.1%

ordinateur 85.5%

souris 0.1%

DÉMONSTRATION

CONCLUSION

Nous avons développé un système complet de reconnaissance de gestes de langue des signes, combinant :

- **YOLOv8** pour la détection des mains
- **MediaPipe** Hands pour l'extraction des keypoints
- Un modèle **LSTM** bidirectionnel pour la classification
- Une **application web** intuitive pour la prédiction en temps réel

REMERCIEMENTS



